

Registro de Decisiones de Arquitectura (ADR) — RLKA

Proyecto: RLKA — Roof Leopard Knowledge Agent

Código de documento: DOC-ADR-RLKA-001 **Elaborado por:** Camila Fonseca Rojas (Analista de Arquitectura de Soluciones) **Fecha:** 05 de julio de 2026

ADR-001: Selección de plataforma de despliegue

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 05 de julio de 2026 **Decide:** Camila Fonseca Rojas (Analista de Arquitectura de Soluciones)

Contexto

El proyecto requiere desplegar la aplicación en un entorno accesible públicamente, con evidencia verificable de su funcionamiento (enlace público o captura de pantalla). El equipo ya cuenta con experiencia previa usando Supabase y Netlify en otro proyecto de la empresa (Marketing Console), lo cual representaba una alternativa de bajo esfuerzo. Sin embargo, ese stack es financiado por la empresa (Roof Leopard Roofing Company), y su uso para este proyecto — que forma parte de un programa de certificación personal — planteaba un conflicto de uso apropiado de recursos corporativos.

Adicionalmente, el proyecto se origina dentro de un programa de certificación co-creado con Oracle (Oracle Tech Builder / Alura ONE), cuyo objetivo pedagógico incluye demostrar capacidad de despliegue en Oracle Cloud Infrastructure (OCI).

Decisión

Se despliega la aplicación en **Oracle Cloud Infrastructure**, utilizando una instancia de cómputo del nivel **Always Free**, bajo cuenta personal de la desarrolladora — no bajo la cuenta corporativa de Roof Leopard Roofing Company.

Alternativas consideradas

Alternativa

Razón de descarte

Supabase + Netlify (stack ya usado en la empresa)

Financiado por la empresa; su uso para un proyecto de certificación personal no corresponde a un fin corporativo legítimo

N8N (herramienta low-code)

El proyecto exige explícitamente “código para leer y procesar el documento”; un flujo visual de N8N no cumple este requisito de forma literal, aunque sea funcionalmente equivalente

Consecuencias

Positivas: - Cumple el objetivo pedagógico del programa de certificación. - No genera conflicto de uso de recursos financiados por terceros. - La cuenta y la infraestructura quedan bajo control directo de la desarrolladora.

Negativas / riesgos aceptados: - Configuración de red en OCI (VCN, security lists, puertos) representa la fase de mayor riesgo de retraso del proyecto (ver riesgo R-01 en el documento de diagnóstico). - No es la plataforma que el equipo ya domina; implica una curva de aprendizaje adicional respecto a Supabase/Netlify.

Reconsideración futura: si el proyecto avanza a una fase de producción real dentro de Roof Leopard Roofing Company (fuera del alcance de este ADR), esta decisión debe revisarse — en ese escenario sí correspondería evaluar el stack financiado por la empresa. -e—

ADR-002: Selección de vector store

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 05 de julio de 2026 **Decide:** Camila Fonseca Rojas (Analista de Arquitectura de Soluciones)

Contexto

El agente requiere un mecanismo de búsqueda por similitud semántica sobre los fragmentos de los documentos fuente. Existen alternativas gestionadas (bases de datos vectoriales en la nube, como Supabase con la extensión pgvector) y alternativas embebidas que corren dentro del mismo proceso de la aplicación, sin necesidad de infraestructura externa.

Tal como se estableció en el ADR-001, el proyecto no utiliza infraestructura financiada por la empresa (Supabase). Esto excluye directamente cualquier alternativa de vector store gestionado que dependiera de esa cuenta.

Decisión

Se utiliza un **vector store local embebido** — FAISS o ChromaDB — que se ejecuta dentro del mismo proceso de la aplicación y guarda su índice en disco.

Alternativas consideradas

Alternativa

Razón de descarte

Supabase (pgvector)

Depende de infraestructura financiada por la empresa (ver ADR-001); además, agrega una dependencia de red externa innecesaria para el volumen de datos del proyecto (3 documentos)

Servicio de vector store gestionado de terceros (ej. Pinecone)

Requiere cuenta adicional y credenciales de terceros; no aporta beneficio frente a una solución local para este volumen de datos

Consecuencias

Positivas: - No requiere cuentas ni credenciales adicionales. - No depende de conectividad de red durante la ejecución de las búsquedas. - Reduce puntos de falla en el despliegue.

Negativas / limitaciones aceptadas: - No escala de forma automática a volúmenes grandes de documentos; suficiente para el alcance actual (3 documentos), pero requeriría reevaluación si el proyecto crece significativamente en una fase futura. - El índice debe reconstruirse si cambian los documentos fuente; no hay actualización incremental automática en esta fase. -e —

ADR-003: Formato de documento fuente

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 05 de julio de 2026 **Decide:** Camila Fonseca Rojas (Analista de Arquitectura de Soluciones)

Contexto

Los documentos fuente disponibles (Política de Warranty, Manual de Procedimientos Operativos, Política de RRHH) existen originalmente en formato Markdown. El programa de certificación establece como requisito mínimo que el agente sea capaz de leer y procesar al menos un documento en formato PDF o CSV. Los documentos no contienen datos tabulares, por lo que CSV no es un formato apropiado para su contenido.

Decisión

Los tres documentos fuente se **convierten de Markdown a PDF** antes de ser ingeridos por el agente. Se decide convertir los tres documentos disponibles, no solo el mínimo de uno requerido, para habilitar capacidad de razonamiento cruzado entre documentos (ver Nivel 1, punto 2, en el documento de estrategia del proyecto).

Alternativas consideradas

Alternativa

Razón de descarte

Ingerir un único documento (mínimo requerido)

Reduce la posibilidad de demostrar razonamiento cruzado entre documentos, un diferenciador de bajo costo y alto impacto identificado en la estrategia del proyecto

Formato CSV

El contenido de los documentos es narrativo, no tabular; CSV no es un formato adecuado para este tipo de contenido

Mantener el formato Markdown original sin conversión

No cumple el requisito técnico mínimo del programa de certificación

Consecuencias

Positivas: - Cumple el requisito técnico del programa con margen (3 documentos en vez de 1). - Habilita ejemplos de preguntas que requieren combinar información de más de un documento, un diferenciador identificado como de alto valor.

Negativas / riesgos aceptados: - La conversión de Markdown a PDF puede introducir errores de formato (columnas, tablas mal interpretadas) que afecten la calidad de la extracción de texto posterior; debe validarse el texto extraído antes de construir las capas siguientes (ver riesgo R-02 en el documento de diagnóstico). -e —

ADR-004: Selección del nombre de persona del agente

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 05 de julio de 2026 **Decide:** Camila Fonseca Rojas (Analista de Arquitectura de Soluciones)

Contexto

El agente requiere un nombre de persona bajo el cual se presenta al usuario final, distinto de la sigla técnica del proyecto (RLKA), que es apropiada para documentación de arquitectura pero poco natural en una conversación en lenguaje natural. Se necesita un nombre que mantenga relación con la identidad del proyecto y de la empresa (Roof Leopard Roofing Company), sin resultar excesivamente formal ni técnico de cara al usuario.

Decisión

El agente se presenta al usuario bajo el nombre **RoofKA**. Este nombre se utiliza en el saludo inicial y en los diálogos previstos del agente (ver Especificación de diálogos y persona del agente, documento de implementación), mientras que la sigla **RLKA** se mantiene como identificador técnico del proyecto en la documentación de arquitectura.

Alternativas consideradas

Alternativa

Razón de descarte

RLKA (usar la misma sigla técnica como nombre de persona)

Poco natural para un saludo conversacional; adecuado para documentación, no para diálogo con el usuario final

DocuMind, ConsultaIA, KnowBase Agent (nombres genéricos evaluados en etapas previas)

No conservan relación directa con la identidad de Roof Leopard Roofing Company

Consecuencias

Positivas: - Mantiene coherencia con el nombre de la empresa y del proyecto sin resultar técnico de cara al usuario final. - Facilita un tono conversacional más natural en los diálogos definidos del agente.

Negativas / consideraciones aceptadas: - Introduce dos identificadores distintos para el mismo proyecto (RLKA a nivel técnico/documental, RoofKA a nivel de persona conversacional); debe mantenerse claridad en la documentación sobre cuál corresponde a cada contexto para evitar confusión. —

ADR-005: Selección del modelo de embeddings

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 05 de julio de 2026 **Decide:** Camila Fonseca Rojas (Analista de Arquitectura de Soluciones)

Contexto

Durante la validación local del pipeline de indexación (ADR-002), se realizó una prueba de búsqueda real con la pregunta “¿Cuánto dura la garantía de un techo completo?” contra los chunks generados de los documentos fuente. Se detectó que, usando el modelo all-MiniLM-L6-v2 (variante entrenada principalmente en inglés), el chunk que contenía la respuesta correcta obtenía una similitud de apenas 0.42-0.46, mientras que chunks irrelevantes obtenían puntajes más altos (0.49-0.53). El chunk correcto no aparecía ni siquiera dentro de los primeros 10 resultados.

Este comportamiento indicaba que el modelo no estaba diferenciando correctamente el significado semántico en español — los puntajes de similitud eran esencialmente ruido, sin relación clara con la relevancia real del contenido.

Decisión

Se reemplaza el modelo de embeddings por **paraphrase-multilingual-MiniLM-L12-v2** (sentence-transformers), una variante entrenada específicamente para múltiples idiomas, incluyendo español.

Evidencia de la decisión
(diagnóstico real)

Modelo
Similitud del chunk correcto
Posición en el top 10
all-MiniLM-L6-v2 (solo inglés)
0.425
No aparece (fuera del top 10)
paraphrase-multilingual-MiniLM-L12-v2
0.723
Puesto #1

Alternativas consideradas

Alternativa
Razón de descarte
Mantener all-MiniLM-L6-v2 y solo ajustar el chunking/texto fuente

Insuficiente por sí solo — se probó primero (agregando un resumen en lenguaje natural en la fuente) y la mejora fue marginal ($0.425 \rightarrow 0.457$), sin resolver el problema real

Usar un modelo de embeddings vía API externa (OCI Generative AI / Cohere)

Introduce dependencia de red y credenciales durante la fase de prototipado local, contradiciendo el principio de “local primero, nube después” (ver Diagnostico_ASIS_TOBE_RLKA, sección 2.3)

Consecuencias

Positivas: - Mejora sustancial y medible en la calidad de recuperación semántica en español (de posición fuera del top 10, a posición #1). - Sigue siendo un modelo local, gratuito, sin API key — no cambia ninguna otra decisión de arquitectura (ADR-001, ADR-002).

Negativas / consideraciones aceptadas: - El modelo es más grande (471 MB vs ~90 MB del anterior), por lo que la primera descarga y carga es más lenta. - Debe usarse este mismo modelo de forma consistente en todo el proyecto (documentos y preguntas del usuario) — ya está centralizado en una única función (`get_embedding_model()` en `vectorstore.py`) para evitar inconsistencias. -e —

ADR-006: Herramienta de extracción de texto desde PDF

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 07 de julio de 2026 **Decide:** Silvia Zamora Valverde (Desarrolladora del proyecto)

Contexto

Durante la construcción del pipeline de ingesta (ingest.py), se evaluaron 3 herramientas de extracción de texto desde PDF: pdfplumber, PyMuPDF, y pdftotext (poppler-utils). Al procesar el documento de Warranty, se detectó que tanto pdfplumber como PyMuPDF descartan por completo la tabla de la Sección 6 (duración de garantía por tipo de trabajo) — el texto extraído omite la tabla sin generar ningún error, lo cual hacía el problema difícil de detectar sin una revisión manual del contenido extraído.

Decisión

Se utiliza pdftotext en modo "-layout" (parte de poppler-utils) como herramienta de extracción, en lugar de una librería de Python pura. Este modo preserva la disposición espacial del texto, incluyendo el contenido tabular que las otras herramientas descartaban.

Alternativas consideradas

Alternativa	Razón de descarte
pdfplumber	Descarta por completo la tabla de duración de garantías del documento Warranty, sin generar ningún error visible
PyMuPDF (fitz)	Presenta el mismo problema que pdfplumber con el contenido tabular del documento Warranty
pdftotext -layout (poppler-utils)	Extrae correctamente la tabla; requiere una dependencia de sistema operativo en vez de solo una librería Python (aceptado como consecuencia menor)

Consecuencias

Positivas: - Preserva contenido crítico (la tabla de garantías) que de otro modo quedaría invisible para el agente. - Evita una clase de error silencioso particularmente difícil de detectar (ausencia de datos sin mensaje de error).

Negativas / consideraciones aceptadas: - Requiere instalar poppler-utils como dependencia de sistema operativo en cada entorno de ejecución (Google Colab, Streamlit Community Cloud), documentado explícitamente como requisito en ingest.py y en packages.txt.

ADR-007: Estrategia de chunking (división en fragmentos)

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 07 de julio de 2026 **Decide:** Silvia Zamora Valverde (Desarrolladora del proyecto)

Contexto

La primera version del chunking dividia el texto de cada pagina a tamano fijo, sin considerar los limites de parrafo o seccion. Durante la validacion, se detecto que en el documento de RRHH, el final de la Seccion 12 quedaba mezclado con el inicio de la Seccion 13 dentro de un mismo fragmento, lo cual bajaba la similitud semantica del fragmento relevante por debajo del umbral de confianza durante la recuperacion.

Decisión

Se cambia el chunking a un esquema que respeta los limites de parrafo (separados por linea en blanco), empaquetando parrafos completos hasta un limite de tamano de 800 caracteres, con solapamiento de 150 caracteres entre fragmentos consecutivos. Si un parrafo individual excede el tamano de fragmento, se aplica como fallback un corte de tamano fijo unicamente sobre ese parrafo.

Alternativas consideradas

Alternativa	Razón de descarte
Corte a tamaño fijo ciego (versión original)	Mezcla contenido de secciones no relacionadas, degradando la calidad de la recuperación semántica
Chunking semántico basado en NLP (ej. segmentación por similitud entre oraciones)	Mayor precisión potencial, pero agrega complejidad y dependencias adicionales fuera de proporción para el alcance de 3 documentos del proyecto
Chunking por límites de párrafo con fallback a tamaño fijo	Evita mezclar secciones sin agregar dependencias nuevas; suficiente para la estructura de los 3 documentos fuente

Consecuencias

Positivos: - Elimina la mezcla de contenido entre secciones no relacionadas (validado en el documento de RRHH). - No agrega dependencias nuevas al proyecto.

Negativas / consideraciones aceptadas: - Párrafos muy cortos pueden generar fragmentos pequeños que dependen más del solapamiento con fragmentos vecinos para mantener contexto suficiente.

ADR-008: Selección del LLM de generación

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 08 de julio de 2026 **Decide:** Silvia Zamora Valverde (Desarrolladora del proyecto)

Contexto

El agente requiere un modelo de lenguaje para generar la respuesta final a partir del contexto recuperado. Durante las primeras pruebas se intento usar el modelo "command-r" de Cohere, el cual fue descontinuado en septiembre de 2025, generando errores 404 al intentar invocarlo.

Decisión

Se utiliza la API de Cohere con el modelo "command-a-03-2025", bajo una clave de prueba (trial). El prompt instruye explícitamente al modelo a responder únicamente a partir del contexto recuperado, citar la fuente exacta (documento y página), y declarar explícitamente cuando la información no está disponible en los documentos.

Alternativas consideradas

Alternativa	Razón de descarte
OpenAI GPT (API)	Requiere método de pago registrado desde el inicio del período de prueba, a diferencia de Cohere
Modelo local vía Hugging Face (ej. Llama, Mistral)	Exige más cómputo del disponible en el entorno de despliegue previsto (Streamlit Community Cloud)
Cohere command-a-03-2025	Trial gratuito con cuota mensual (20 llamadas) suficiente para el alcance de validación del proyecto

Consecuencias

Positivas: - Sin costo durante el desarrollo y la validación. - API sencilla de integrar, sin necesidad de gestionar infraestructura de cómputo propia para el LLM.

Negativas / consideraciones aceptadas: - La cuota de prueba (20 llamadas/mes) condiciona el volumen de pruebas reales que pueden ejecutarse en producción sin exceder el límite; se monitorea el consumo manualmente durante la fase de validación.

ADR-009: Ajuste de parámetros de recuperación (top_k y umbral de confianza)

Proyecto: RLKA — Roof Leopard Knowledge Agent **Estado:** Aceptado **Fecha:** 08 de julio de 2026 **Decide:** Silvia Zamora Valverde (Desarrolladora del proyecto)

Contexto

Las pruebas con preguntas cortas (3 palabras o menos) mostraban recall insuficiente usando el valor por defecto de top_k. Adicionalmente, el proyecto requiere que el agente reconozca cuando una pregunta esta fuera del alcance de los 3 documentos disponibles, en lugar de generar una respuesta sin respaldo real en el contenido (alucinacion).

Decisión

Se incrementa el top_k por defecto de 4 a 6 fragmentos recuperados. Para preguntas de 3 palabras o menos, se aplica una expansion adicional a top_k=8. Se establece ademas un umbral de confianza de 0.45: si la similitud del mejor fragmento recuperado no alcanza ese umbral, el agente responde con un mensaje de "no tengo esa informacion" en lugar de invocar al LLM de generacion.

Alternativas consideradas

Alternativa	Razón de descarte
top_k fijo sin ajuste por longitud de pregunta	Insuficiente para preguntas cortas, donde el contexto disponible en la pregunta misma es limitado
Sin umbral de confianza (dejar que el LLM decida cuándo no tiene información)	Riesgo de alucinación: el LLM puede generar una respuesta plausible aunque el contexto recuperado no la respalde realmente
top_k dinámico + umbral de confianza fijo	Combina recall adecuado para preguntas cortas con un mecanismo explícito y verificable de rechazo ante preguntas fuera de alcance

Consecuencias

Positivas: - Mejora el recall en preguntas cortas. - Reduce el riesgo de alucinación ante preguntas fuera de alcance, con un mecanismo explícito y auditable.

Negativas / consideraciones aceptadas: - El umbral de 0.45 fue calibrado empíricamente contra las preguntas de prueba disponibles durante el desarrollo; podría requerir recalibración si el conjunto de documentos fuente cambia significativamente en el futuro.

Adenda — 09 de julio de 2026: Revisión de ADR-001

Contexto de la revisión

Se consultó directamente al canal de soporte oficial del programa (OneSource) para confirmar el alcance real del requisito de OCI planteado en ADR-001. Respuesta oficial: el uso de Oracle Cloud Infrastructure es una recomendación del programa, no una obligación — el único requisito real es que el proyecto sea accesible mediante una URL pública.

Decisión revisada

Se descarta el despliegue en OCI Compute planteado originalmente en ADR-001. El despliegue permanece en Streamlit Community Cloud, plataforma donde el agente ya estaba validado en producción, evitando una migración de infraestructura no obligatoria a pocos días del cierre del proyecto.

Nota: esta adenda no invalida el razonamiento original del ADR-001 (evitar el uso de infraestructura corporativa financiada por Roof Leopard Roofing Company para un proyecto de certificación personal) — ese principio se mantiene y sigue siendo relevante para justificar por qué tampoco se usó Supabase/Netlify en este despliegue final.

Ver docs/Log_Cambios_RLKA.md (entrada 2026-07-09) para el detalle completo de la consulta y la decisión.